

Especificación Técnica: AI Interaction Runtime Enforcement

Arquitectura de Cuatro Planos para el Control Pre-Flight de Modelos de Inteligencia Artificial

Principio Rector Oficial: «Política gobernada centralmente. Decisión ejecutada localmente. Evidencia verificable criptográficamente.»


Tesis Operacional: «La seguridad deja de preguntar qué ocurrió con el prompt y empieza a decidir si ese prompt debe llegar a existir como solicitud para el proveedor.»

1. RESUMEN EJECUTIVO Y FRONTERA DE CONTROL

S.A.A.R.E. es una plataforma distribuida de *AI Interaction Runtime Enforcement* que sitúa el punto de decisión y control en el **Pre-Flight L7 del cliente**, antes de que una interacción se convierta en una solicitud HTTP/WebSocket dirigida al proveedor de IA (Google Gemini, OpenAI, Anthropic, Copilot o endpoints privados).

Bajo el estándar **Zero-Submission Enforcement**, cualquier interacción clasificada como BLOCK es neutralizada en origen, garantizando que el proveedor procesa **exactamente 0 tokens**, eliminando costes de inferencia, riesgos de reentrenamiento de terceros y sanciones bajo el marco del *EU AI Act (Art. 15)*, *RGPD* y *ENS Nivel Alto*.

2. ARQUITECTURA DISTRIBUIDA EN CUATRO PLANOS





3. DESGLOSE FUNCIONAL DE PLANOS

Plano	Componentes Principales	Función y Garantía Técnica
1. Control Plane	Policy Registry, Tenant Management, Versioning Engine.	Compila, sella y distribuye paquetes de políticas firmados criptográficamente (<i>Policy Bundles</i>) a toda la flota de endpoints sin intermediar en la toma de decisiones críticas de tráfico.
2. Data Plane	Pre-Flight Hook L7, Evaluation Engine en memoria efímera.	Ejecuta la evaluación en el endpoint a velocidad sub-milisegundo (P50 1.4 ms). Soporta acciones ALLOW, BLOCK, SANITIZE y WARN de forma desacoplada y offline-first.
3. Evidence Plane	Append-Only Vault, Hash-Chain, W3C WebCrypto Inspector.	Construye el <i>Decision Record</i> inmutable enlazando el hash previo de la cadena pericial, sellando la versión de política activa (<i>policy_hash</i>) y firma asimétrica de hardware.
4. Governance Plane	SOC Dashboard (console.saare.es), RunLive Telemetry.	Supervisión en tiempo real, verificación de evidencias periciales frente al registro público y auditoría continua de cumplimiento regulatorio.

4. MÉTRICAS DE RENDIMIENTO Y BENCHMARK FORENSE

La evaluación local se ejecuta en un buffer efímero sin retención de datos en texto plano. Las métricas de latencia de decisión registradas en laboratorio son:

- **Latencia Mediana (P50):** 1.4 ms en evaluación de expresiones complejas y políticas de privacidad.
- **Latencia P95:** 3.1 ms bajo inspección heurística simultánea de jailbreak y detección de PII.
- **Latencia P99:** 4.8 ms incluyendo sellado criptográfico y adición al buffer de evidencias.